

Vigilancia epidemiológica en Colombia: pipeline ETL y análisis inferencial de las notificaciones de dengue

Eventos de notificación obligatoria registrados en SIVIGILA, 2018-2022

AUTORES	Juan Pablo Izquierdo Corral Juan Sebastián Sánchez Urbano Juan Felipe Enrique Obando
LUGAR Y FECHA	Santiago de Cali, Colombia · octubre de 2026
FUENTE	Instituto Nacional de Salud (INS): reportes de vigilancia rutinaria 2018-2022
ALCANCE	Dengue, IRAG inusitada y tuberculosis · 33 departamentos · periodicidad semanal
PALABRAS CLAVE	SIVIGILA, ETL, arquitectura medallón, calidad de datos, dengue, estacionalidad, regresión binomial negativa

Resumen

Este documento reúne el proyecto completo sobre los eventos de notificación obligatoria registrados en SIVIGILA entre 2018 y 2022: un **pipeline ETL reproducible** con arquitectura medallón (Bronze, Silver y Gold) y un **análisis inferencial de las notificaciones de dengue**. El pipeline consolida cinco reportes rutinarios del Instituto Nacional de Salud en un almacén de datos de 457.227 registros y 86 eventos, con reporte de calidad, panel interactivo y 21 pruebas automáticas. La auditoría de la fuente mostró que la tabla dinámica de 2022 cuenta filas en lugar de sumar casos: el dengue de 2022 aparecía con 12.513 casos y la suma correcta es 65.691. Con la serie corregida, el dengue reúne **360.125 notificaciones en 32 departamentos**. La prueba de Friedman exacta no encuentra un orden trimestral común entre años ($p = 0,408$), pero la interacción año $\times$ trimestre del modelo binomial negativo es clara ($F(12, 31) = 14,86$; $p < 0,001$): el cuarto trimestre superó al primero en cuatro años y 2020 fue la excepción. Son conteos de notificaciones, sin población como denominador ni variables climáticas, por lo que el trabajo no estima tasas ni atribuye el patrón al clima.

Contenido

1. Introducción y planteamiento del problema	4
1.1 Contexto	4
1.2 Problema y árbol de problema	4
1.3 Preguntas de investigación	5
2. Objetivos	5
3. Usuarios y alcance	6
4. Fuentes de datos	6
4.1 Reportes rutinarios de SIVIGILA	6
4.2 Información demográfica y otras fuentes	7
5. Arquitectura del pipeline ETL	7
5.1 Visión general	7
5.2 Capa Bronze (extract.py)	8
5.3 Capa Silver (transform.py)	8
5.4 Capa Gold y esquema estrella (load.py)	9
5.5 Panel interactivo (dashboard)	10
5.6 Calidad de ingeniería y reproducibilidad	10
6. Auditoría y calidad de los datos	10
6.1 Hallazgos de la auditoría	10
6.2 Reconciliación del dengue	11
6.3 Indicadores de calidad	12
7. Resultados descriptivos	12
7.1 Los tres eventos del proyecto	12
7.2 Tuberculosis e IRAG: definiciones y comparabilidad	14
7.3 Dengue 2018-2022	14
7.4 El quiebre de IRAG inusitada en 2022	16
8. Metodología del análisis inferencial	16
8.1 Unidad de análisis y panel	16
8.2 Variables	16
8.3 Trimestres epidemiológicos	17
8.4 Contraste del patrón trimestral	17
8.5 Modelo de conteos	17
8.6 Criterios de interpretación	17

9. Resultados inferenciales	17
9.1 Perfil trimestral y prueba de Friedman	17
9.2 Modelo de conteos	19
9.3 Diagnóstico y dependencia residual	20
10. Concentración territorial	20
11. Discusión y limitaciones	21
12. Conclusiones	22
13. Trabajo futuro	23
Referencias	23
Anexo A. Esquema del almacén de datos	24
Anexo B. Eventos objetivo y códigos	24
Anexo C. Huellas SHA-256 de los archivos fuente	25
Anexo D. Estructura del proyecto y ejecución	25
Anexo E. Glosario	26

1. Introducción y planteamiento del problema

1.1 Contexto

En Colombia, los eventos de interés en salud pública registrados mediante el Sistema de Vigilancia en Salud Pública (SIVIGILA) presentan variaciones temporales y territoriales según el evento, el periodo epidemiológico y la entidad territorial. Algunos eventos transmitidos por vectores pueden concentrarse en determinados periodos, mientras que otros se comportan de forma distinta entre departamentos y municipios.

SIVIGILA recopila información con variables temporales, geográficas y demográficas. Sin embargo, para comparar de manera reproducible es necesario integrar, depurar y estandarizar los datos, porque los reportes difieren en formatos, nombres de eventos, periodos, niveles territoriales y valores faltantes. La información distribuida en varias fuentes y formatos genera reprocesos manuales y dificulta identificar patrones temporales y territoriales.

Este proyecto responde a esa dificultad en dos frentes: primero, construye un pipeline ETL que integra, depura y documenta los reportes rutinarios del INS; segundo, aplica sobre una serie auditada de dengue métodos de inferencia adecuados para datos de conteo. El resultado es exploratorio: no pretende reemplazar los sistemas oficiales de vigilancia, establecer causalidad ni realizar predicciones operativas.

1.2 Problema y árbol de problema

El problema central identificado es la **falta de anticipación estadística ante la dispersión estacional de las enfermedades notificadas**. Sus consecuencias son la sobrecarga de servicios en picos no anticipados, el retraso en la activación de campañas de prevención, la distribución ineficiente de recursos entre departamentos y municipios, y una morbilidad evitable por enfermedades estacionales. Las causas raíz son la ausencia de análisis estadístico de estacionalidad por enfermedad, la falta de integración de las series temporales con la demografía, el uso limitado de modelos predictivos en las decisiones y la dispersión de los datos en múltiples fuentes y formatos.




Figura 1. Árbol de problema: efectos (parte superior), problema central y causas raíz (parte inferior).

Tabla 1. Respuesta del proyecto a las causas raíz del árbol de problema.

Causa raíz	Respuesta del proyecto	Estado
Datos dispersos sin consolidar	Cinco libros Excel con hojas, encabezados y códigos distintos se consolidan en una tabla larga y en un almacén de datos SQLite.	Atendida
Variables no integradas (series temporales y demografía)	Se une la población por departamento y año para calcular tasas por 100.000 habitantes; la cifra poblacional disponible es constante entre años (ver sección 4.2).	Parcial
Falta de análisis estadístico de estacionalidad	Coeficiente de variación, índice estacional, prueba de Friedman exacta y regresión binomial negativa para el dengue.	Atendida para dengue
Uso limitado de modelos predictivos	Fuera del alcance exploratorio del proyecto.	Pendiente

1.3 Preguntas de investigación

El proyecto responde a dos preguntas complementarias:

- Ingeniería de datos:** ¿cómo integrar, homologar y auditar cinco reportes rutinarios con estructuras distintas para obtener una serie confiable, trazable y reproducible?
- Inferencia:** ¿cómo varió el número de notificaciones de dengue por año, trimestre epidemiológico y departamento durante 2018-2022, y se repite un patrón trimestral comparable entre años?

2. Objetivos

Objetivo general. Diseñar e implementar un pipeline ETL reproducible que integre, depure y estandarice los reportes rutinarios de SIVIGILA 2018-2022 y, sobre la serie auditada, caracterizar e inferir los patrones temporales y territoriales de las notificaciones de dengue en Colombia.

Objetivos específicos.

- Consolidar y documentar los cinco reportes rutinarios y la información demográfica en tres capas de datos (Bronze, Silver y Gold).
- Homologar eventos, territorios y periodos epidemiológicos, y documentar la calidad de los datos: faltantes, duplicados, subtotales y registros no homologables.
- Auditar la comparabilidad de los eventos seleccionados (dengue, IRAG inusitada y tuberculosis) y verificar los totales contra la fuente.
- Generar indicadores descriptivos reproducibles (casos por periodo y territorio, coeficiente de variación) y un panel de consulta.
- Evaluar si las diferencias entre trimestres epidemiológicos mantienen un orden consistente entre años mediante una prueba no paramétrica bloqueada por año.
- Estimar la asociación del año y del trimestre con el número semanal de notificaciones mediante un modelo de conteo ajustado por departamento, revisando su dispersión, la dependencia residual y la incertidumbre.

3. Usuarios y alcance

Usuarios principales. Los equipos de vigilancia epidemiológica y analítica de las Secretarías de Salud departamentales y municipales, y los epidemiólogos y analistas de datos del Instituto Nacional de Salud (INS), responsables de monitorear semanalmente las enfermedades de notificación obligatoria y de decidir sobre la distribución de recursos sanitarios. Manejan un alto volumen de reportes, tienen formación técnica en salud pública y un nivel heterogéneo en estadística avanzada; por eso necesitan información procesada, consolidada y visualizada con claridad más que datos crudos.

Usuarios secundarios. Investigadores académicos, estudiantes de salud pública o ciencia de datos interesados en el comportamiento epidemiológico estacional, y directivos que emplean resultados agregados para política pública y planeación presupuestal de campañas de prevención.

Alcance. Eventos: dengue (código 210), IRAG inusitada (348) y tuberculosis. Periodo: 2018-2022. Nivel territorial: departamento. Periodicidad: semana epidemiológica. Los resultados describen asociaciones sobre conteos de notificaciones; no establecen causalidad, no estiman riesgo individual y no sustituyen los sistemas oficiales de vigilancia.

4. Fuentes de datos

4.1 Reportes rutinarios de SIVIGILA

La fuente principal son los cinco libros de Excel *rutinaria_2018.xlsx* a *rutinaria_2022.xlsx*, descargados del portal oficial del INS (consulta del 3 de octubre de 2026). Cada libro aporta casos notificados por evento, departamento y semana epidemiológica. Son **conteos agregados de casos notificados**, no microdatos por caso: no traen edad, sexo ni población expuesta.

Los libros no comparten estructura: las hojas se llaman distinto cada año, el encabezado cambia de fila, las columnas de semana varían de formato y aparecen filas de subtotal. En 2022 la hoja resumen es una tabla dinámica defectuosa, de modo que se lee la hoja de detalle (ver sección 6).

Tabla 2. Archivos fuente y estrategia de lectura. Las huellas SHA-256 de cada archivo están en el Anexo C.

Año	Archivo	Tamaño	Hoja utilizada	Lectura	Semanas	Filas (largo)
2018	rutinaria_2018.xlsx	21,7 MB	EventoDepartamento	Tabla dinámica	52	99.424
2019	rutinaria_2019.xlsx	8,2 MB	Eventos	Tabla dinámica	52	98.072
2020	rutinaria_2020.xlsx	8,1 MB	Por eventos	Tabla dinámica	53	97.414
2021	rutinaria_2021.xlsx	5,9 MB	Evento	Tabla dinámica	52	82.992
2022	rutinaria_2022.xlsx	11,8 MB	Datos_para_estadistica_rutinari	Detalle (suma de conteo)	52	91.832
Total						469.734

4.2 Información demográfica y otras fuentes

La población por departamento y año se toma del archivo *poblacion_departamentos.csv* (33 departamentos × 5 años = 165 filas). Su limitación principal es que **repite la misma cifra en los cinco años** (44.164.417 habitantes a nivel nacional cada año), por lo que no refleja el crecimiento poblacional y las tasas por 100.000 habitantes quedan sesgadas. Por esa razón el análisis inferencial trabaja con conteos y no con tasas. Reemplazar el archivo por las proyecciones del DANE por departamento y año es la mejora de mayor prioridad.

Tabla 3. Fuentes consideradas y estado de integración.

Fuente	Uso previsto	Estado	Observaciones
SIVIGILA (INS)	Eventos de notificación obligatoria por semana y territorio.	Integrada	Cinco reportes rutinarios 2018-2022, casos agregados.
DANE	Proyecciones poblacionales para tasas de incidencia.	Parcial	Población total por departamento; cifra constante entre años; sin nivel municipal ni grupos de edad.
IDEAM	Precipitación y temperatura para explorar asociación con estacionalidad.	No integrada	Pendiente de evaluar cobertura y compatibilidad.
Ministerio de Salud y Protección Social	Capacidad instalada y red hospitalaria.	No integrada	Necesaria solo para analizar sobrecarga de servicios.
datos.gov.co	Indicadores complementarios de salud pública.	No integrada	Sin uso por ahora.

5. Arquitectura del pipeline ETL

5.1 Visión general

El pipeline sigue la arquitectura medallón: **Bronze** conserva los datos cercanos a la fuente, **Silver** los depura y homologa, y **Gold** los organiza para el análisis. Una etapa adicional genera el panel interactivo. Todo se ejecuta con una sola orden y cada etapa deja constancia de lo que hizo en archivos de metadatos y de calidad.



Figura 2. Arquitectura del pipeline: fuentes, capas Bronze, Silver y Gold, productos y elementos de orquestación.

5.2 Capa Bronze (extract.py)

- Detecta la hoja correcta de cada libro a partir de una lista de candidatas por año, ubica la fila de encabezado y las columnas de semana, y pasa los datos de formato ancho a formato largo (año, código, evento, departamento, semana, casos).
- Rellena hacia abajo el código y el nombre del evento **por bloque de evento**. Un relleno global heredaba el código del evento anterior cuando venía vacío y fusionaba eventos distintos.
- Si un código falta, lo recupera por el nombre del evento en otro año; lo que no puede resolver queda registrado en la metadata como no resuelto.
- Para 2022 lee la hoja de detalle, suma la columna de conteo por evento, departamento y semana, y genera ceros explícitos para todas las semanas de cada par observado. Contrasta el resultado con la tabla dinámica y deja una advertencia con la discrepancia.
- Escribe *sivigila_bronze.csv*, *poblacion_bronze.csv* y *metadata_extraccion.json* (hoja, estrategia, filas, advertencias y códigos imputados por archivo).

5.3 Capa Silver (transform.py)


1. **Subtotales.** Se identifican por departamento vacío, código no numérico o etiqueta «Total». Antes de retirarlos se **reconcilian** contra la suma por departamento: 7.245 de 7.245 totales de 2019 y 2020 coinciden.
2. **Eventos sin código.** Se excluyen 2.192 filas (Intoxicaciones 2021 y Chagas crónico 2020) y se registra una advertencia.
3. **Homologación.** Texto en mayúsculas y sin tildes (NARIÑO se vuelve NARINO), «DESCONOCIDO» unificado como «PROCEDENCIA DESCONOCIDA» y nombre canónico de cada evento por **código** (el del año más reciente).
4. **Validaciones.** Duplicados exactos y colisiones de código (0 casos) y rangos válidos: semana entre 1 y 53, casos no negativos (0 filas fuera de rango).
5. **Territorio y calendario.** Se marca si el registro es territorial (departamento) o no (Exterior, Procedencia desconocida). El mes se calcula con el calendario epidemiológico: semanas de domingo a sábado, semana 1 como la primera con al menos cuatro días de enero y mes asignado según el miércoles de la semana.
6. **Población.** Se une por departamento y año y se calcula la tasa por 100.000 habitantes para los registros territoriales con población.

Tabla 4. Flujo de registros entre Bronze y Silver.

Paso	Filas	Nota
Registros en Bronze	469.734	Cinco años, todos los eventos, con subtotales de origen
Subtotales retirados	-10.315	Reconciliados antes de retirarse
Eventos sin código retirados	-2.192	Intoxicaciones 2021 y Chagas crónico 2020
Duplicados, colisiones y rangos inválidos	0	Sin hallazgos
Registros en Silver	457.227	86 eventos • 35 valores de territorio • 261 semanas

5.4 Capa Gold y esquema estrella (load.py)

Gold construye un almacén de datos SQLite con **esquema estrella real**: llaves primarias y foráneas, índices y verificación de integridad en cada carga. La tabla de hechos guarda los casos por evento, departamento y semana; las dimensiones describen eventos, territorios y tiempo. Además se generan dos vistas de consulta y exportes en CSV con los casos de los eventos objetivo y los indicadores.



Vistas: v_casos_objetivo · v_casos_mensuales
Tablas auxiliares: evento_objetivo_map · indicadores_cv · calidad_datos

Figura 3. Esquema estrella del almacén de datos (sivigila_dw.db).

Tabla 5. Contenido del almacén de datos (23,6 MB). Vistas: v_casos_objetivo y v_casos_mensuales.

Tabla	Filas	Descripción
hecho_casos	457.227	Casos por evento, departamento y semana (PK compuesta de las tres llaves)
dim_evento	86	Eventos por código único
dim_departamento	35	33 departamentos más Exterior y Procedencia desconocida; indicador es_territorial
dim_tiempo	261	Año, semana, mes epidemiológico y fecha de inicio de semana
poblacion_departamento	165	Población por departamento y año
evento_objetivo_map	19	Grupo analítico y códigos de evento por año
indicadores_cv	15	Coeficiente de variación mensual y semanal (3 eventos × 5 años)
calidad_datos	18	Métricas del reporte de calidad

Los eventos objetivo se definen por **código y año** en un único archivo de configuración, lo que permite ampliar el análisis a otros eventos sin modificar el código de las etapas (Anexo B). Gold ya no duplica la tabla completa de hechos en CSV (33 MB); esa exportación es opcional.

5.5 Panel interactivo (dashboard)

El panel es un archivo HTML autocontenido, sin librerías externas ni conexión a internet, que se genera automáticamente con los resultados de la última corrida. Presenta indicadores clave, series semanales por evento y año, comparación anual, índice estacional mensual, departamentos con más casos, tabla de coeficientes de variación, auditoría de calidad, registro de extracción por archivo y las advertencias detectadas por el pipeline. Se regenera con `python run_pipeline.py --solo dashboard` y admite cargar el archivo `casos_objetivo.csv` de otra corrida.

5.6 Calidad de ingeniería y reproducibilidad

- **Configuración central** (`config.py`): rutas, hojas candidatas por año, eventos objetivo y correcciones documentadas.
- **Orquestador** (`run_pipeline.py`): ejecuta todas las etapas o solo algunas con `--desde` y `--solo`; registra el tiempo de cada una.
- **Registro de calidad** por etapa: metadatos de extracción, reporte de calidad con advertencias y reconciliación de totales.
- **Pruebas automáticas** (21): utilidades y calendario epidemiológico, lectura y relleno por bloque, imputación de códigos, subtotales y reconciliación, llave única, tasas, integridad del almacén, configuración y comprobaciones de cordura sobre los resultados reales (por ejemplo, que el dengue de 2022 supere los 50.000 casos).
- **Reproducibilidad**: una corrida desde cero en carpeta limpia tarda unos 41 segundos y produce exactamente los mismos resultados.

6. Auditoría y calidad de los datos

6.1 Hallazgos de la auditoría

La auditoría contrastó el pipeline contra las hojas del propio INS (tablas por evento y por municipio) y contra los totales de origen. Los hallazgos que cambian los resultados se resumen a continuación.

Tabla 6. Hallazgos de la auditoría, causa y tratamiento.

#	Hallazgo	Causa	Tratamiento	Efecto
1	Todo 2022 estaba subestimado unas cuatro veces	La tabla dinámica de 2022 cuenta filas del detalle en lugar de sumar la columna de conteo	Se lee la hoja de detalle y se suma el conteo	Dengue 2022: 12.513 a 65.691 casos; total 2022: 215.210 a 823.705
2	Eventos fusionados en 2021 (tuberculosis farmacoresistente y dos tipos de malaria)	Un relleno global heredaba el código del evento anterior cuando venía vacío	Relleno por bloque y recuperación del código por nombre	Códigos 825, 470 y 490 recuperados
3	Tuberculosis no comparable entre años	En 2021 el INS publica un único código (813) con todas las formas	Serie «todas las formas» (810 + 820; 813 en 2021) y serie pulmonar (820) por separado	Serie completa de cinco años
4	Nombres de evento distintos según el año	Tildes y siglas	Identificación por código	Se eliminan 15 códigos duplicados de la dimensión de eventos
5	Subtotales mezclados con datos	Filas «Total» de las tablas dinámicas	Reconciliación y retiro	7.245 de 7.245 totales coinciden
6	Eventos sin código en el origen	Celda de código vacía sin equivalente en otros años	Exclusión con advertencia	Intoxicaciones 2021 (18.901 casos) y Chagas crónico 2020 (98 casos) quedan fuera
7	Mes aproximado con una fórmula	4,33 semanas por mes	Calendario epidemiológico real	Cambian levemente los CV mensuales
8	Procedencias no territoriales	Exterior y Procedencia desconocida no pertenecen a un departamento	Indicador es_territorial; se excluyen del análisis inferencial	812 casos de dengue excluidos

6.2 Reconciliación del dengue

La serie de dengue (código 210) se reconcilió año por año. La primera columna recoge los valores del avance previo del proyecto; la última, la serie usada en el análisis inferencial (32 departamentos). Las cifras del pipeline y las del análisis inferencial, calculadas con código independiente, coinciden exactamente una vez excluidos Exterior y Procedencia desconocida.

Tabla 7. Reconciliación de dengue por año. (*) El valor 25.026 duplicaba las 12.513 filas de la tabla dinámica de 2022 y no representa casos.

Año	Valor en el avance previo	Todas las procedencias	Excluidos (exterior / desconocida)	Analizado (32 departamentos)
2018	43.652	43.652	395	43.257
2019	122.998	122.998	6	122.992
2020	76.220	76.220	0	76.220
2021	52.376	52.376	148	52.228
2022	25.026 *	65.691	263	65.428
Total		360.937	812	360.125

Detalle de 2022: la hoja de detalle contiene 12.513 filas de dengue y 65.691 casos al sumar el conteo, incluidos otros países; al restringir a ocurrencia en Colombia quedan 12.406 filas y 65.428 casos.

6.3 Indicadores de calidad

Tabla 8. Indicadores de calidad de la última corrida.

Indicador	Valor	Nota
Registros con territorio válido	97,61 %	El 2,39 % restante corresponde a Exterior y Procedencia desconocida
Registros homologados territorialmente (con población asociada)	97,61 %	Departamentos territoriales con población
Registros con código de evento	99,53 %	2.192 de 469.734 filas de Bronze no traen código
Registros con semana válida (1 a 53)	100 %	0 filas fuera de rango
Duplicados exactos	0 %	Llave única año, código, departamento y semana
Totales de origen reconciliados	100 %	7.245 de 7.245 (años 2019 y 2020, que traen totales por evento)
Eventos / valores de territorio / semanas	86 / 35 / 261	33 departamentos más Exterior y Procedencia desconocida
Códigos con más de un nombre entre años	11	Se unifican por código; conviene revisar subtipos (por ejemplo, Chagas agudo y crónico, código 205)

7. Resultados descriptivos

7.1 Los tres eventos del proyecto

Los casos anuales de los tres eventos muestran dinámicas muy distintas: el dengue alcanza su máximo en 2019, la IRAG inusitada crece con fuerza en 2020 y 2022, y la tuberculosis se mantiene estable con una caída en 2020. Las cifras de esta sección incluyen todas las procedencias.

Tabla 9. Casos notificados por evento y año (todas las procedencias).

Año	Dengue (210)	IRAG inusitada (348)	Tuberculosis, todas las formas
2018	43.652	1.288	13.998
2019	122.998	835	14.255
2020	76.220	21.765	11.023
2021	52.376	954	14.132
2022	65.691	107.290	17.154




Figura 4. Casos notificados por evento y año, 2018-2022.

El **coeficiente de variación (CV) mensual** resume la dispersión de los casos mensuales dentro de cada año (desviación estándar muestral sobre la media, sobre casos nacionales). La tuberculosis es el evento más estable; la IRAG inusitada es el más disperso, con 118,0 % en 2020.

Tabla 10. Coeficiente de variación mensual por evento y año. El CV semanal figura en el almacén de datos (tabla indicadores_cv).

Año	Dengue	IRAG inusitada	Tuberculosis (todas las formas)
2018	45,3 %	60,3 %	12,8 %
2019	24,2 %	32,9 %	12,8 %
2020	74,6 %	118,0 %	21,6 %
2021	57,6 %	95,2 %	16,7 %
2022	26,3 %	83,9 %	13,2 %




Figura 5. Coeficiente de variación mensual por evento y año.

7.2 Tuberculosis e IRAG: definiciones y comparabilidad

Tuberculosis. Hasta 2020 y en 2022 el INS reporta la forma pulmonar (código 820) y la extrapulmonar (810) por separado. En 2021 publica un único código (813) que agrupa todas las formas y no permite separar la pulmonar. Por eso el pipeline construye la serie «todas las formas» (810 + 820; 813 en 2021), comparable en los cinco años. El análisis inferencial, que usa la tuberculosis solo como contexto, conserva la serie pulmonar y deja 2021 como **no disponible** en lugar de asumir que equivale a cero.

Tabla 11. Tuberculosis según el código de evento (todas las procedencias). Restringida a departamentos, la serie pulmonar es 11.715; 12.237; 9.433; no disponible; 15.033.

Año	Pulmonar (820)	Extrapulmonar (810)	Código 813 (todas las formas)	Todas las formas (serie del pipeline)
2018	11.940	2.058	—	13.998
2019	12.237	2.018	—	14.255
2020	9.433	1.590	—	11.023
2021	No disponible	No disponible	14.132	14.132
2022	15.189	1.965	—	17.154

IRAG. Se usa el código 348 (IRAG inusitada) y no el 345, que corresponde a la vigilancia centinela (ESI-IRAG) y es un evento distinto.

Tabla 12. IRAG inusitada por año.

Código	2018	2019	2020	2021	2022
348, todas las procedencias	1.288	835	21.765	954	107.290
348, solo departamentos	1.248	835	21.765	953	107.076

7.3 Dengue 2018-2022

Desde esta sección el análisis se limita a los **32 departamentos** con registros de dengue, sin Exterior ni Procedencia desconocida. Bogotá no aparece porque no tiene ningún registro de dengue en los libros; se conservan los ceros dentro de cada par evento-departamento observado, y el panel queda completo: 8.352 observaciones (32 departamentos × 261 semanas).

Tabla 13. Dengue notificado en los 32 departamentos analizados. 2020 tiene 53 semanas epidemiológicas.

Año	Casos	Semanas	Promedio semanal	% del total
2018	43.257	52	832	12,0 %
2019	122.992	52	2.365	34,2 %
2020	76.220	53	1.438	21,2 %
2021	52.228	52	1.004	14,5 %
2022	65.428	52	1.258	18,2 %
Total	360.125	261		100 %

El máximo anual ocurre en 2019 (122.992 casos, 34,2 % del total quinquenal) y el mínimo en 2018. Tanto el nivel como la trayectoria semanal cambian de un año a otro, de modo que una sola curva estacional no resume bien el periodo.




Figura 6. Casos nacionales de dengue por semana epidemiológica y año (el año 2020 incluye la semana 53).




Figura 7. Serie nacional continua de notificaciones semanales. La conexión cronológica permite ver el paso entre años; no implica que los cambios de un año sean causados por los del anterior.

- **Continuidad 2019-2020.** Las notificaciones altas de fines de 2019 continúan al inicio de 2020; el máximo nacional de 2020 ocurre en la semana 6 (3.663 casos).
- **Caída entre las semanas 11 y 12 de 2020.** Pasa de 2.855 a 1.821 casos (−36,2 %). Coincide con el periodo inicial de la pandemia, pero la serie por sí sola no permite atribuirla a las cuarentenas: también pudieron influir cambios en consulta, diagnóstico y vigilancia.
- **Última semana de 2021.** Las notificaciones bajan de 1.766 a 701 casos (−60,3 %) entre las semanas 51 y 52. Podría reflejar un corte de reporte, pero no se verificó con una fuente externa; esa semana forma parte del cuarto trimestre de 2021.
- **Dispersión del panel.** La media de casos por departamento y semana es 43,1 con varianza de 7.181 (cociente aproximado de 166), el 9,3 % de las observaciones son ceros y el máximo es 1.452 (Valle del Cauca, semana 10 de 2020). Esta sobredispersión justifica un modelo distinto de Poisson.

7.4 El quiebre de IRAG inusitada en 2022

La serie semanal de IRAG inusitada en 2022 casi no registra casos hasta la semana 16 (apenas 0,4 % del total anual en esas semanas) y luego salta: 347 casos en la semana 17, 1.739 en la 18 y entre aproximadamente 3.100 y 4.800 por semana entre las semanas 19 y 33. Bogotá concentra 36.726 casos (34 %). El patrón es compatible con un cambio en la definición o en la notificación del evento, pero no se verificó la causa con una fuente externa. En cambio, el aumento de 2020 (21.765 casos) es consistente con la pandemia.




Figura 8. IRAG inusitada: casos semanales por año. Se destacan 2020 y 2022.

8. Metodología del análisis inferencial

8.1 Unidad de análisis y panel

La unidad principal es el **conteo de dengue por departamento y semana epidemiológica** (código de evento 210). Se excluyen las procedencias Exterior y Desconocida para mantener una comparación territorial nacional homogénea. El año 2020 tiene 53 semanas y los demás 52. Los libros no incluyen edad, sexo ni población expuesta.

8.2 Variables

Tabla 14. Variables del análisis principal. Año y trimestre se incorporan como factores.

Variable	Tipo	Escala	Función en el análisis
Año (2018-2022)	Cualitativa ordinal	Ordinal	Predictor; bloque en la prueba de Friedman
Trimestre (T1-T4)	Cualitativa ordinal	Ordinal	Predictor temporal principal
Departamento (32)	Cualitativa nominal	Nominal	Ajuste y conglomerado
Semana (1-53)	Índice temporal discreto	Intervalo	Unidad temporal; define el trimestre
Casos notificados	Cuantitativa discreta	Razón	Variable respuesta (conteo)
Código de evento (210)	Cualitativa nominal	Nominal	Filtro para seleccionar dengue; constante tras el filtrado, no es predictor

8.3 Trimestres epidemiológicos

Los trimestres son bloques de semanas: T1 (semanas 1-13), T2 (14-26), T3 (27-39) y T4 (40-52/53). No son estaciones meteorológicas.

8.4 Contraste del patrón trimestral

Se calcula el promedio nacional semanal de cada trimestre en cada año. La **prueba de Friedman** compara entonces el orden de T1 a T4 entre los cinco años sin confundirlo con que un año haya tenido más casos que otro. La hipótesis nula plantea que los rangos trimestrales no difieren; la alternativa, que al menos uno cambia. Se usa $\alpha = 0,05$ y se reporta la W de Kendall como tamaño del efecto. Con cinco bloques y sin empates se enumeran las $(4!)^5 = 7.962.624$ permutaciones para obtener el valor p exacto.

8.5 Modelo de conteos

Se ajusta primero un modelo **Poisson** con año, trimestre y departamento como factores. La dispersión se revisa con la suma de los residuos de Pearson al cuadrado dividida por sus grados de libertad, que en Poisson debería ser cercana a uno. Como el valor observado resulta mucho mayor, se usa una **regresión binomial negativa**, que permite que la varianza supere la media, y se incluye la interacción año $\times$ trimestre porque el patrón puede cambiar entre años. La interacción se evalúa con una prueba de Wald robusta. Los contrastes comparan T4 con T1 dentro de cada año, con errores robustos agrupados por departamento (32 conglomerados) y valores p ajustados con el método de Holm (cinco contrastes).

8.6 Criterios de interpretación

- Los resultados describen **asociaciones**, no causas ni efectos del clima.
- Sin población como denominador se comparan conteos de notificaciones, no tasas de incidencia ni riesgos individuales.
- El valor p no mide el tamaño del efecto: se interpretan las razones estimadas, sus intervalos y las limitaciones del diseño.
- No se remuestran semanas como si fueran independientes, porque se ignoraría la dependencia temporal. Remuestrear departamentos completos sería una alternativa de sensibilidad; aquí se optó por Friedman exacta y errores robustos agrupados por departamento.

Herramientas. La preparación de datos y la generación de tablas y gráficos usan Python; los modelos estadísticos se ajustaron en R. Los datos procesados y el código se entregan para reproducir el análisis.

9. Resultados inferenciales

9.1 Perfil trimestral y prueba de Friedman

La tabla siguiente muestra el promedio nacional de notificaciones por semana en cada trimestre. Descriptivamente, en 2020 el primer trimestre superó al cuarto y en los otros cuatro años ocurrió lo contrario.




Figura 9. Media nacional de casos de dengue por semana en cada trimestre epidemiológico, separada por año.

Tabla 15. Promedio de notificaciones nacionales por semana en cada trimestre.

Año	T1	T2	T3	T4
2018	438	664	871	1.354
2019	1.740	2.557	2.617	2.547
2020	3.077	1.363	712	661
2021	641	583	940	1.854
2022	882	1.250	1.348	1.552

Tabla 16. Rangos dentro de cada año, ordenados de menor a mayor promedio semanal.

Año	Rango T1	Rango T2	Rango T3	Rango T4
2018	1	2	3	4
2019	1	3	4	2
2020	4	3	2	1
2021	2	1	3	4
2022	1	2	3	4
Suma de rangos	9	11	15	15

Resultado. Friedman exacta: $Q(3) = 3,24$; $p = 0,408$; W de Kendall = 0,216. Con $\alpha = 0,05$ no se rechaza la hipótesis nula. Esto no prueba que el perfil trimestral sea igual entre años: con solo cinco bloques la prueba tiene baja potencia y el resultado debe leerse con cautela.

Verificación independiente. A partir de la tabla anterior se recalcularon los rangos, $Q = 3,24$ y $W = 0,216$, y se enumeraron las 7.962.624 permutaciones para obtener el valor p exacto (0,4076, que se redondea a 0,408). El resultado coincide con el análisis original.

Observación exploratoria. En el primer trimestre de 2020, Valle del Cauca aportó 14.806 de los 39.999 casos (37,0 %). Aun sin ese departamento, el promedio semanal nacional de T1 (1.938) sigue superando al de T4 (478), de modo que la inversión de 2020 no depende de un solo departamento. Es un cálculo descriptivo, sin contraste formal.

9.2 Modelo de conteos

Con la misma estructura de predictores (año × trimestre + departamento), el modelo Poisson produjo una razón de dispersión de **30,3**, muy superior a uno, por lo que sus pruebas ordinarias serían poco fiables. La binomial negativa redujo esa razón a **1,24** y el AIC pasó de 252.785 a 65.637. La prueba conjunta de la interacción año × trimestre, con covarianza robusta agrupada por departamento, fue **F(12, 31) = 14,86; p < 0,001**, lo que sustenta perfiles intraanuales diferentes.

Tabla 17. Contrastes T4 frente a T1 dentro de cada año (binomial negativa con interacción, errores robustos agrupados por departamento). Una razón mayor que 1 indica más notificaciones semanales esperadas en T4 que en T1, no mayor riesgo individual.

Año	Media T1	Media T4	Razón ajustada T4/T1	IC 95 %	p bruto	p Holm
2018	438	1.354	2,65	1,76-4,00	< 0,001	< 0,001
2019	1.740	2.547	1,38	0,99-1,93	0,060	0,085
2020	3.077	661	0,25	0,18-0,35	< 0,001	< 0,001
2021	641	1.854	2,35	1,48-3,73	< 0,001	0,002
2022	882	1.552	1,45	1,01-2,08	0,043	0,085




Figura 10. Razón ajustada T4/T1 con intervalo de confianza del 95 % por año. La línea punteada marca la ausencia de diferencia (razón = 1).

La comparación T4/T1 **cambia de dirección**: en 2018 la razón ajustada es 2,65 (IC 95 %: 1,76-4,00), mientras que en 2020 es 0,25 (0,18-0,35). Después del ajuste de Holm queda evidencia estadística para 2018, 2020 y 2021; los contrastes de 2019 y 2022 se consideran exploratorios. No hay un único multiplicador trimestral que describa los cinco años. Agrupar por departamento considera la dependencia dentro de cada territorio, pero no resuelve posibles choques semanales que afecten a varios departamentos a la vez.

Sensibilidad. Al repetir la prueba de Wald robusta de la interacción sin 2020 (6.656 observaciones) se obtiene F(9, 31) = 5,20; p = 0,000251. La interacción persiste en los cuatro años restantes, lo que indica que no depende únicamente de 2020; esto no identifica una causa ni elimina la autocorrelación y otras limitaciones del diseño.

9.3 Diagnóstico y dependencia residual

Los gráficos de residuos de Pearson del modelo binomial negativo con interacción muestran valores extremos y una distribución asimétrica a la derecha; por sí solos no prueban que los supuestos se cumplan. La autocorrelación residual de primer orden promedió **0,62**, de modo que el modelo no captura toda la dependencia temporal. La agrupación robusta por departamento considera la dependencia dentro de cada territorio, pero no resuelve los choques semanales comunes; las inferencias y sus intervalos deben interpretarse con cautela.

10. Concentración territorial

Los diez departamentos con más notificaciones acumuladas reúnen la mayor parte de la carga reportada. Valle del Cauca, Meta y Tolima concentran 30,9 % del total analizado. Es una comparación de **conteos acumulados, no de riesgo**: comparar riesgo entre departamentos exigiría denominadores poblacionales y considerar diferencias en diagnóstico y notificación.




Figura 11. Diez departamentos con mayor número acumulado de notificaciones de dengue, 2018-2022.

Tabla 18. Diez mayores conteos acumulados de dengue y su distribución por año.

Departamento	Total	% total	2018	2019	2020	2021	2022
Valle del Cauca	50.724	14,1 %	2.284	7.378	28.300	8.546	4.216
Meta	30.930	8,6 %	4.485	16.906	2.702	1.508	5.329
Tolima	29.696	8,2 %	3.255	14.845	6.779	1.572	3.245
Atlántico	28.346	7,9 %	3.246	3.905	2.613	8.434	10.148
Bolívar	25.184	7,0 %	1.347	5.243	2.440	9.255	6.899
Huila	20.718	5,8 %	1.094	10.659	6.606	1.215	1.144
Santander	18.524	5,1 %	2.630	9.651	3.424	954	1.865
Norte de Santander	17.996	5,0 %	4.830	6.356	1.220	3.078	2.512
Cesar	16.777	4,7 %	2.072	7.152	2.219	2.192	3.142
Córdoba	16.708	4,6 %	3.880	4.803	1.674	2.500	3.851

La composición cambia mucho de un año a otro: Norte de Santander (11,2 %), Meta (10,4 %) y Córdoba (9,0 %) lideran en 2018; Meta (13,7 %), Tolima (12,1 %) y Huila (8,7 %) en 2019; Valle del Cauca concentra 37,1 % en 2020 (28.300 de 76.220 casos); Bolívar (17,7 %), Valle del Cauca (16,4 %) y Atlántico (16,1 %) en 2021; y Atlántico (15,5 %), Bolívar (10,5 %) y Meta (8,1 %) en 2022. Esta rotación es coherente con perfiles temporales que no se repiten de un año a otro.

11. Discusión y limitaciones

Calidad y definición del dato. La revisión de la hoja de 2022 corrigió el total del avance previo. Se dejó registro de los códigos que aparecen, de las sumas obtenidas y de las huellas SHA-256 de los cinco libros fuente. En tuberculosis pulmonar, 2021 queda como no disponible porque en esa hoja no aparece el código 820; la serie «todas las formas» del pipeline resuelve la comparabilidad al costo de agrupar formas clínicas distintas.

Inferencia temporal. Friedman no mostró un orden trimestral común entre los cinco años, pero con solo cinco bloques su potencia es baja. La prueba de Wald robusta de la interacción año × trimestre sí encontró diferencias entre perfiles. La autocorrelación residual de primer orden fue alta (0,62) y quedan choques semanales compartidos sin modelar, de modo que los intervalos son aproximados. Además, cinco años son pocos para generalizar.

Alcance epidemiológico. La base contiene notificaciones agregadas: no permite estimar incidencia ni riesgo individual y no incluye población expuesta, edad, sexo, clima ni mediciones de cambios en la vigilancia. Por eso no se atribuyen las diferencias a la lluvia, la urbanización u otras causas.

Tabla 19. Limitaciones principales y mejora propuesta.

Limitación	Efecto sobre los resultados	Mejora propuesta
Población constante entre años	Las tasas por 100.000 habitantes quedan sesgadas; el análisis se limita a conteos	Cargar proyecciones DANE por departamento y año
Quiebre de IRAG inusitada en 2022	El CV y la estacionalidad de ese año reflejan probablemente un cambio de notificación	Confirmar con el INS y definir su tratamiento
Eventos sin código (Intoxicaciones 2021, Chagas crónico 2020)	Quedan fuera del almacén de datos	Asignar código en la configuración
Caída en la última semana de 2021	Puede afectar el promedio de T4 de 2021	Verificar corte de reporte y evaluar sensibilidad
Datos agregados	Sin edad ni sexo; sin tasas por grupo etario	Evaluar microdatos si el análisis lo exige
Sin clima (IDEAM)	No se puede estudiar la asociación con precipitación o temperatura	Verificar cobertura e integrar
Casos notificados, no confirmados; efecto de la pandemia en 2020-2021	Posibles cambios en consulta, diagnóstico y vigilancia	Interpretar con cautela y documentarlo

Nota sobre la verificación de cifras. Al compilar este documento se verificaron de forma independiente, con los datos procesados por el pipeline, los totales anuales y el total de 360.125 casos, las 8.352 observaciones, los promedios trimestrales, la prueba de Friedman (estadístico, W de Kendall y valor p exacto), los departamentos con más casos y los valores semanales citados. Los resultados del modelo binomial negativo (dispersión, AIC, pruebas de Wald, razones T4/T1, ajuste de Holm, sensibilidad sin 2020 y autocorrelación residual) provienen del análisis en R del equipo y no se volvieron a ejecutar aquí.

12. Conclusiones

- Se construyó un pipeline ETL reproducible.** Cinco libros con estructuras distintas se consolidan en 457.227 registros y 86 eventos, con esquema estrella, panel interactivo, reporte de calidad y 21 pruebas automáticas. Una corrida limpia toma unos 41 segundos y reproduce los mismos resultados.
- La auditoría evitó conclusiones erróneas.** La tabla dinámica de 2022 contaba filas, no casos (dengue 2022: 12.513 frente a 65.691); en 2021 la tuberculosis no se separa por forma. Ambas decisiones quedaron documentadas y cubiertas por pruebas.
- La serie depurada de dengue contiene 360.125 notificaciones** en 32 departamentos, 8.352 observaciones y 261 semanas epidemiológicas; 2019 concentra el máximo anual (122.992 casos, 34,2 %).
- No hay un perfil trimestral común.** Friedman exacta no encuentra evidencia suficiente de un orden uniforme ($p = 0,408$, con baja potencia), mientras que la interacción año $\times$ trimestre es clara ($F(12, 31) = 14,86$; $p < 0,001$). La razón T4/T1 va de 2,65 en 2018 a 0,25 en 2020, y la interacción persiste sin 2020 ($F(9, 31) = 5,20$).
- La carga reportada se concentra en pocos departamentos:** Valle del Cauca, Meta y Tolima suman 30,9 %, pero la composición rota cada año. Es carga de notificación, no riesgo territorial.
- Las limitaciones son claras:** población constante entre años, ausencia de clima, quiebre de IRAG inusitada en 2022 y autocorrelación residual alta. Los resultados son exploratorios y no sustituyen a los sistemas oficiales de vigilancia.

13. Trabajo futuro

1. Cargar la población del DANE por departamento y año, recalcular las tasas de incidencia y repetir la comparación territorial con denominadores.
2. Confirmar con el INS el quiebre de IRAG inusitada en 2022 y definir su tratamiento en las pruebas de estacionalidad.
3. Resolver los eventos sin código (Intoxicaciones 2021 y Chagas crónico 2020).
4. Evaluar la integración de variables climáticas del IDEAM, según su cobertura, para estudiar su asociación con el dengue.
5. Aplicar el análisis de sensibilidad por remuestreo de departamentos completos y modelos que incorporen la dependencia temporal.
6. Ampliar el pipeline a más eventos, incluidos algunos crónicos, y al nivel municipal.
7. Evaluar el uso de microdatos para analizar edad y sexo.

Referencias

Instituto Nacional de Salud. *Estadísticas de Vigilancia Rutinaria*, series rutinaria_2018.xlsx a rutinaria_2022.xlsx. Portal SIVIGILA. Consultado el 3 de octubre de 2026.

Cameron, A. C. y Trivedi, P. K. (2013). *Regression Analysis of Count Data* (2.ª ed.). Cambridge University Press.

Cameron, A. C. y Miller, D. L. (2015). A practitioner's guide to cluster-robust inference. *Journal of Human Resources*, 50(2), 317-372.

Friedman, M. (1937). The use of ranks to avoid the assumption of normality implicit in the analysis of variance. *Journal of the American Statistical Association*, 32(200), 675-701.

Kendall, M. G. y Babington Smith, B. (1939). The problem of m rankings. *The Annals of Mathematical Statistics*, 10(3), 275-287.

Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65-70.

Anexo A. Esquema del almacén de datos

Tabla 20. Tablas del almacén de datos.

Tabla	Columnas	Restricciones
dim_evento	evento_id, cod_evento, evento	PK evento_id; cod_evento único
dim_departamento	departamento_id, departamento, es_territorial	PK departamento_id; departamento único; es_territorial en {0, 1}
dim_tiempo	tiempo_id, anio, semana, mes, fecha_inicio_semana	PK tiempo_id; (anio, semana) único; semana 1-53; mes 1-12
poblacion_departamento	departamento_id, anio, poblacion	PK (departamento_id, anio); FK a dim_departamento
hecho_casos	evento_id, departamento_id, tiempo_id, casos	PK compuesta; tres FK; casos ≥ 0; índices por tiempo y por departamento
evento_objetivo_map	grupo, anio, cod_evento	PK (grupo, anio, cod_evento)
indicadores_cv	grupo, anio, n_meses, media, sd y cv mensual; n_semanas, media, sd y cv semanal	PK (grupo, anio)
calidad_datos	metrica, valor	PK metrica

Ejemplo de consulta con la vista de casos de los eventos objetivo:

```
SELECT grupo, anio, SUM(casos) AS casos
FROM v_casos_objetivo
GROUP BY grupo, anio
ORDER BY grupo, anio;
```

Anexo B. Eventos objetivo y códigos

Tabla 21. Códigos de evento utilizados.

Grupo	Código(s) por año	Observación
Dengue	210 (2018-2022)	Identificable en los cinco años
IRAG inusitada	348 (2018-2022)	El código 345 corresponde a vigilancia centinela y no se usa
Tuberculosis, todas las formas	810 + 820 (2018, 2019, 2020, 2022); 813 (2021)	Serie comparable de cinco años
Tuberculosis pulmonar (contexto inferencial)	820 (2018, 2019, 2020, 2022)	2021 no disponible: el código 813 no separa la forma pulmonar
Tuberculosis farmacorresistente (recuperado)	825	En 2021 llegó sin código y se recuperó por nombre
Malaria falciparum y vivax (recuperados)	470 y 490	En 2021 llegaron sin código y se recuperaron por nombre

Anexo C. Huellas SHA-256 de los archivos fuente

Las huellas permiten comprobar que los libros usados en el pipeline son idénticos a los descargados del portal del INS.

Tabla 22. Huellas SHA-256 de rutinaria_2018.xlsx a rutinaria_2022.xlsx.

Año	Tamaño	SHA-256
2018	21,7 MB	f73304a6423e66827f506d3d69f4647ea17aee5711de4961398c68a4d2d918f3
2019	8,2 MB	07d065326ce7ffc980793fa19d771394da79c87518cb1735450712be62758c35
2020	8,1 MB	798b5b9f6ff7077ee1b995312944fa5306895eb1e85e200994842d9b071ae129
2021	5,9 MB	1b06664ce6581a74a10b0ed804b9d52c3759e9cb02dd178c2a4ff88ba961018d
2022	11,8 MB	81273ed3cd8e8544123cad168996c7dd7e7c00bb80194beb127c8d5e0be45e1b

Anexo D. Estructura del proyecto y ejecución

```
proyecto_etl_sivigila/
├── config.py           rutas, hojas por año, eventos objetivo, correcciones
├── run_pipeline.py     orquestador (extract, transform, load, dashboard)
├── requirements.txt    pandas, numpy, openpyxl
├── etl/
│   ├── extract.py     capa Bronze
│   ├── transform.py   capa Silver
│   ├── load.py        capa Gold (esquema estrella SQLite)
│   ├── dashboard.py   inyecta resultados en la plantilla HTML
│   └── utils.py        logging, texto, calendario epidemiológico
├── dashboard/
│   ├── dashboard_template.html
│   └── dashboard_sivigila.html
├── data/
│   ├── raw/           rutinaria_2018..2022.xlsx, poblacion_departamentos.csv
│   ├── bronze/ silver/ gold/ salidas de cada capa
├── tests/test_pipeline.py 21 pruebas automáticas
└── docs/INFORME_HALLAZGOS.md correcciones y pendientes
```

Ejecución del pipeline.

```
pip install -r requirements.txt
# copiar rutinaria_2018.xlsx ... rutinaria_2022.xlsx en data/raw/
python run_pipeline.py           # corrida completa (~45 s)
python run_pipeline.py --desde transform # si Bronze ya existe
python run_pipeline.py --solo dashboard # solo regenerar el panel
python -m unittest discover -s tests -v # pruebas
```

Análisis inferencial. Se descargan los cinco libros en la carpeta de datos fuente y se ejecutan, en este orden, el script de preparación de datos (Python), el análisis estadístico (R) y el generador de informe (Python). Los CSV procesados, el código, el archivo de dependencias y la información de sesión de R se entregan junto con el análisis. Los archivos fuente originales no se alteran.

Anexo E. Glosario

Tabla 23. Términos y siglas usados en el documento.

Término	Significado
SIVIGILA	Sistema de Vigilancia en Salud Pública de Colombia, a cargo del INS
INS	Instituto Nacional de Salud
DANE	Departamento Administrativo Nacional de Estadística (proyecciones de población)
IDEAM	Instituto de Hidrología, Meteorología y Estudios Ambientales (variables climáticas)
ETL	Extracción, transformación y carga de datos
Arquitectura medallón	Organización de datos en capas Bronze (cruda), Silver (depurada) y Gold (analítica)
Esquema estrella	Modelo con una tabla de hechos rodeada de tablas de dimensiones
IRAG inusitada	Infección respiratoria aguda grave inusitada (código 348)
Semana epidemiológica	Semana de domingo a sábado; la semana 1 es la primera con al menos cuatro días de enero
T1 a T4	Trimestres epidemiológicos: semanas 1-13, 14-26, 27-39 y 40-52/53
CV	Coefficiente de variación: desviación estándar dividida por la media
Friedman	Prueba no paramétrica para comparar varios grupos medidos en los mismos bloques (aquí, años)
W de Kendall	Tamaño del efecto asociado a Friedman, entre 0 y 1
Binomial negativa	Modelo de conteos que admite varianza mayor que la media (sobredispersión)
Errores robustos agrupados	Errores estándar que consideran dependencia dentro de cada conglomerado (aquí, departamento)
Holm	Corrección de valores p por comparaciones múltiples